

PROJEKT: STOCK MARKET SIMULATION

KOD KURSU: 120-ISI-1S-777

**PRZEDMIOT: SYMULACJA SYSTEMÓW DYSKRETNYCH
(SSD)**

Autorzy projektu

Daniel Sterzel
Szymon Kowalski
Michał Król

Opiekun projektu

prof. dr hab. inż. Jarosław Wąs
mgr Filip Kamiński



EAIiIB / Katedra Informatyki Stosowanej
Akademia Górniczo-Hutnicza im. Stanisława Staszica w
Krakowie
Kraków, Polska

16 stycznia 2026

Spis treści

Abstract	iv
1 CEL I ZAKRES PROJEKTU	1
1.1 Cel projektu	1
1.2 Oczekiwane rezultaty	1
2 Charakterystyka problemu	2
2.1 Opis charakterystyki problemu	2
2.2 Mechanizm Arkusza Zleceń (Limit Order Book)	2
2.3 Heterogeniczność agentów	2
2.4 Zmienność i płynność (Volatility vs Liquidity)	3
2.5 Wyzwania techniczne i modelowe	3
3 Dane porównawcze	5
3.1 Źródła danych rynkowych	5
3.2 Charakterystyka wybranych scenariuszy	5
3.3 Dane syntetyczne i walidacja techniczna	6
3.4 Metoda przetwarzania i eksportu danych	6
4 MODEL FORMALNY	7
4.1 Model formalny symulacji	7
4.1.1 Reprezentacja arkusza zleceń	7
4.1.2 Algorytm silnika dopasowującego z kolejką opóźnień	7
4.1.3 Mechanizm wymuszonego krachu (Flash Crash)	8
5 Realizacja praktyczna	10
5.1 Założenia projektowe	10
5.2 Komponenty sprzętowe	10
5.3 Oprogramowanie i High Performance Computing	11
5.4 Szczegóły implementacji i wizualizacja	11
5.4.1 Orkiestracja eksperymentów	11
5.4.2 Zaawansowana wizualizacja i redukcja szumu	12

5.4.3	Repozytorium i uruchomienie	12
6	Rezultaty symulacji i analiza eksperymentalna	13
6.1	Eksperyment 1: Wpływ struktury rynku na płynność (HFT vs Market Makers)	13
6.2	Eksperyment 2: Test odporności rynku na szok podaży (Flash Crash)	17
6.3	Eksperyment 3: Mechanizm bańki i psychologia tłumu (Momentum) . .	17
6.4	Eksperyment 4: Granica płynności (Liquidity Cliff) na walorach Nvidia	18
6.5	Eksperyment 5: Walidacja techniczna modelu (Tracking Error)	18
6.6	Podsumowanie wyników eksperymentalnych	19
7	Dyskusja wyników	20
7.1	Trade-off płynności: stabilność vs koszt	20
7.2	Zjawisko „Urwiska Płynności” (Liquidity Cliff)	20
7.3	Psychologia tłumu i zjawisko „Overshootingu”	21
7.4	Weryfikacja techniczna i wpływ opóźnień (Latency)	21
7.5	Ograniczenia modelu	22
8	Podsumowanie	23
8.1	Realizacja celów projektu	23
8.2	Wnioski merytoryczne	23
8.3	Perspektywy rozwoju	24
8.4	Podsumowanie końcowe	24
	Bibliografia	25

Abstract

Przedmiotem projektu jest implementacja i analiza symulacyjnego modelu giełdy papierów wartościowych, opartego na mechanizmie arkusza zleceń (ang. *Limit Order Book*, LOB). Głównym celem pracy było zbadanie, w jaki sposób zróżnicowane strategie agentów — ze szczególnym uwzględnieniem agresywnych spekulantów — wpływają na płynność rynku, zmienność cen oraz szerokość spreadu bid-ask.

Realizacja projektu opiera się na hybrydowym podejściu programistycznym. Wykorzystano język Python do analizy rzeczywistych danych wysokiej częstotliwości (zbiór FI-2010) oraz wyznaczenia realistycznych parametrów wejściowych modelu. Sam silnik symulacyjny (Matching Engine) został zaimplementowany w języku C++, co pozwoliło na osiągnięcie wysokiej wydajności obliczeniowej niezbędnej do procesowania dużej liczby zdarzeń rynkowych w czasie zbliżonym do rzeczywistego.

W ramach prac zaimplementowano zmodyfikowany model Mike-Farmer, wzbogacony o parametry czasu życia zleceń (TTL) oraz opóźnienia sieciowe (latency). Przeprowadzone symulacje pozwoliły na weryfikację hipotezy o negatywnym wpływie nadmiernej agresywności inwestorów na stabilność arkusza zleceń. Wyniki projektu pokazują korelację między proporcją typów agentów a głębokością rynku, co zostało poddane walidacji poprzez porównanie danych syntetycznych z historycznymi szeregami czasowymi.

1. CEL I ZAKRES PROJEKTU

1.1 Cel projektu

Głównym celem projektu jest zbadanie mechanizmów kształtowania się cen oraz dynamiki płynności na uproszczonym modelu giełdy papierów wartościowych. Chcemy sprawdzić, w jaki sposób obecność różnych grup inwestorów – od pasywnych agentów aż po agresywnych spekulantów – wpływa na stabilność rynku.

W szczególności projekt skupia się na odpowiedzi na pytanie badawcze: **jak zwiększony udział traderów o krótkim horyzoncie czasowym i agresywnej strategii wpływa na zmienność cen, szerokość spreadu oraz głębokość arkusza zleceń (LOB)?**

1.2 Oczekiwane rezultaty

Spodziewamy się, że realizacja projektu pozwoli na uzyskanie następujących wyników:

- **Autorski symulator giełdy:** Stabilna aplikacja w C++, zdolna do efektywnego procesowania tysięcy zleceń w modelu Limit Order Book.
- **Weryfikacja hipotezy rynkowej:** Potwierdzenie (lub zaprzeczenie) założenia, że dominacja agentów agresywnych prowadzi do zwiększenia zmienności (volatility) oraz zmniejszenia płynności rynku, co objawia się większym spreadem i częstszym występowaniem zjawiska slippage.
- **Walidacja modelu:** Porównanie wygenerowanych danych syntetycznych z danymi rzeczywistymi z giełd amerykańskich (np. zbiór LOBSTER lub Kaggle). Oczekujemy, że statystyki takie jak rozkład zmian cen i głębokość rynku w symulacji będą wykazywać cechy zbliżone do prawdziwych szeregów czasowych.
- **Raport z analizy danych:** Zbiór wykresów i wniosków wygenerowanych w Pythonie, obrazujących różnice w zachowaniu rynku przy różnych proporcjach typów agentów.

2. Charakterystyka problemu

2.1 Opis charakterystyki problemu

Giełda papierów wartościowych jest klasycznym przykładem systemu złożonego, w którym globalne zachowanie rynku (kursy akcji, zmienność) wynika z tysięcy indywidualnych decyzji podejmowanych przez niezależnych agentów. Kluczowym wyzwaniem w modelowaniu takiego systemu jest fakt, że inwestorzy nie działają w próżni – ich strategie wzajemnie na siebie wpływają, tworząc dynamiczne sprzężenia zwrotne.

2.2 Mechanizm Arkusza Zleceń (Limit Order Book)

Podstawą funkcjonowania współczesnych giełd jest arkusz zleceń (LOB – *Limit Order Book*). Problem badawczy sprowadza się do poprawnego odzwierciedlenia procesu dopasowywania zleceń kupna i sprzedaży. W modelu tym musimy uwzględnić dwa podstawowe typy aktywności:

- **Zlecenia Limit:** Zlecenia oczekujące na konkretną cenę, które budują tzw. głębokość rynku i zapewniają płynność.
- **Zlecenia Market:** Zlecenia realizowane natychmiast po aktualnej cenie rynkowej, które tę płynność „konsumują” i powodują ruchy cenowe.

2.3 Heterogeniczność agentów

W rzeczywistym handlu nie istnieje jeden „typowy” inwestor. Problem badawczy w naszym projekcie opiera się na analizie interakcji między różnymi profilami zachowań:

- **Inwestorzy konserwatywni:** Pełnią rolę *market makerów*, wystawiając zlecenia limit z długim czasem życia (TTL). Ich obecność stabilizuje rynek i zapewnia stałą płynność.

- **Spekulanci agresywni:** Działają szybko, często korzystając ze zleceń market lub z bardzo krótkim czasem TTL. Ich celem jest natychmiastowy zysk, co często prowadzi do drenażu płynności z arkusza.
- **Agenci Momentum:** Zamiast prostego szumu losowego, w modelu zaimplementowano agentów śledzących trend. Reagują oni na historyczne zmiany cen, co pozwala na symulowanie zjawisk takich jak bańki spekulacyjne czy gwałtowne rajdy cenowe (np. fenomen *short squeeze* obserwowany na akcjach spółki Game-Stop - GME).

2.4 Zmienność i płynność (Volatility vs Liquidity)

Głównym problemem, który analizujemy, jest korelacja między typem agenta a parametrami rynkowymi. W warunkach wysokiej zmienności (*volatility*), płynność rynku często zanika, co utrudnia zawieranie transakcji bez znaczącego wpływu na cenę (*slip-page*). Nasza symulacja musi odpowiedzieć na pytanie, przy jakim progu liczebności agentów agresywnych i momentum rynek przestaje być stabilny, a koszty transakcyjne (*spread*) zaczynają gwałtownie rosnąć.

2.5 Wyzwania techniczne i modelowe

Z punktu widzenia implementacji, problemem jest efektywność obliczeniowa. Model Mike-Farmer wymaga ciągłej aktualizacji stanu księgi zleceń i zarządzania setkami tysięcy zdarzeń w czasie rzeczywistym.

Kluczowym wyzwaniem jest modelowanie opóźnień (*latency*). W naszej symulacji zostało to zrealizowane przy pomocy specjalnej kolejki buforowej (*Delay Queue*). Zlecenia wygenerowane przez agentów nie trafiają do arkusza natychmiast – są one "zawieszane" w buforze na czas zależny od typu agenta. Pozwala to na odwzorowanie realnej przewagi technologicznej na rynku:

- **Systemy HFT:** Opóźnienie rzędu 1 ms, co pozwala im niemal natychmiast reagować na zmiany w LOB.
- **Duże instytucje i inwestorzy detaliczni:** Opóźnienie rzędu 100 ms, co symuluje wolniejszy czas reakcji i gorsze warunki dostępu do giełdy.

Ostatnim aspektem problemu jest walidacja – wyniki czysto teoretycznego modelu muszą zostać zestawione z danymi historycznymi (np. FI-2010), aby sprawdzić, czy symulowane przez nas „sztuczne rynki” wykazują te same cechy (tzw. *stylized facts*), co realne rynki finansowe.

3. Dane porównawcze

W celu zapewnienia realizmu symulacji oraz późniejszej walidacji modelu Mike-Farmer, niezbędne było pozyskanie danych referencyjnych z rzeczywistych rynków kapitałowych. Dane te służą do wyznaczenia rozkładów prawdopodobieństwa, którymi posługują się agenci, oraz do porównania statystyk syntetycznych z historycznymi.

3.1 Źródła danych rynkowych

W finalnej wersji projektu zrezygnowano ze statycznych zbiorów danych na rzecz dynamicznego pozyskiwania informacji rynkowych. Wykorzystano w tym celu bibliotekę `yfinance`, która umożliwia bezpośredni dostęp do API Yahoo Finance. Rozwiązanie to pozwoliło na pobieranie danych o wysokiej precyzji (interwały minutowe oraz dzienne) dla szerokiego spektrum aktywów w wybranych oknach czasowych.

3.2 Charakterystyka wybranych scenariuszy

Do walidacji modelu wybrano cztery charakterystyczne instrumenty finansowe, reprezentujące odmienne stany i zachowania rynku:

- **Scenariusz stabilny (Coca-Cola - KO):** Akcje spółki o niskiej zmienności i ugruntowanej pozycji. Dane te posłużyły do badania bazowego spreadu bid-ask oraz stabilności arkusza zleceń w warunkach niskiego szumu.
- **Scenariusz kryzysowy (S&P 500 ETF - SPY, rok 2008):** Dane z okresu kryzysu finansowego. Wykorzystane do przeprowadzenia testów warunków skrajnych (*crash tests*), pozwalających zaobserwować zachowanie modelu przy gwałtownym drenażu płynności.
- **Scenariusz bańki spekulacyjnej (GameStop - GME, rok 2021):** Ekstremalny przypadek wzrostu napędzanego przez inwestorów detalicznych. Dane te by-

ły kluczowe dla testowania agentów typu *Momentum* oraz badania mechanizmu *short squeeze*.

- **Scenariusz wzrostowy (Nvidia - NVDA, rok 2023):** Przykład silnego trendu wzrostowego przy zachowaniu wysokiej płynności. Scenariusz ten pozwolił na analizę wydajności arkusza przy bardzo wysokim wolumenie transakcyjnym.

3.3 Dane syntetyczne i walidacja techniczna

Poza danymi rynkowymi, do modelu wprowadzono sztuczny zbiór danych w postaci ****Sinusoidy****. Jest to zbiór syntetyczny, w którym cena zmienia się według ściśle określonej funkcji matematycznej.

Zastosowanie sinusoidy miało na celu techniczną walidację poprawności algorytmów silnika symulacyjnego. Poprzez obliczanie błędu śledzenia (*Tracking Error*), zespół był w stanie zweryfikować, czy implementacja w C++ poprawnie przetwarza zlecenia i czy agenci reagują na zmiany ceny zgodnie z założoną logiką, bez wpływu przypadkowego szumu rynkowego.

3.4 Metoda przetwarzania i eksportu danych

Proces przygotowania parametrów został zautomatyzowany przy pomocy skryptów w języku Python:

1. **Pobieranie:** Automatyczne zapytania do API `yfinance` dla zdefiniowanych okresów historycznych.
2. **Analiza statystyczna:** Wyznaczenie rozkładów stóp zwrotu, średniej wariancji oraz parametrów wolumenu przy użyciu biblioteki `Pandas`.
3. **Normalizacja:** Przeskalowanie danych rynkowych do jednostek czasu używanych w silniku symulacyjnym.
4. **Eksport:** Zapisanie gotowych profili rynkowych do plików tekstowych w folderze `parameters/`, które są bezpośrednio wczytywane przez moduł C++.

Dzięki połączeniu danych historycznych z różnych epok oraz danych syntetycznych, model posiada szerokie spektrum referencyjne, co pozwala na rzetelną ocenę wpływu różnych typów agentów na zachowanie giełdy.

4. MODEL FORMALNY

4.1 Model formalny symulacji

W celu rzetelnego odwzorowania mechanizmów giełdowych, w projekcie przyjęto model formalny oparty na teorii arkusza zleceń (ang. *Limit Order Book*, LOB). Poniżej przedstawiono matematyczny opis struktury danych oraz algorytm dopasowywania zleceń uwzględniający opóźnienia sieciowe.

4.1.1 Reprezentacja arkusza zleceń

Stan rynku w dowolnej chwili t definiujemy jako parę zbiorów zleceń oczekujących:

$$B = \{b_1, b_2, \dots, b_n\}, \quad A = \{a_1, a_2, \dots, a_m\} \quad (4.1)$$

gdzie B jest zbiorem ofert kupna, a A zbiorem ofert sprzedaży. Każde pojedyncze zlecenie o opisane jest przez rozszerzony zestaw parametrów:

$$o = \langle p, v, t_{in}, TTL, t_{exec} \rangle \quad (4.2)$$

Nowym parametrem jest t_{exec} , czyli czas planowanej egzekucji, obliczany jako $t_{in} + \Delta t$ (gdzie Δt to opóźnienie przypisane do danego typu agenta).

Płynność rynku definiuje spread rynkowy S :

$$S = \min(P_A) - \max(P_B) \quad (4.3)$$

4.1.2 Algorytm silnika dopasowującego z kolejką opóźnień

Wprowadzenie realizmu technicznego wymagało zastosowania mechanizmu *latency-Queue*. Zlecenia nie trafiają do arkusza natychmiast, lecz są procesowane dopiero po upływie zdefiniowanego czasu opóźnienia.

Algorithm 1 Główny krok symulacji (step) z uwzględnieniem opóźnień

```

1: Input: Kolejka zdarzeń rynkowych, stan arkusza  $\{A, B\}$ , latencyQueue
2: Krok 1: Zarządzanie czasem życia (TTL)
3: for każde zlecenie  $o \in \{A, B\}$  do
4:   if  $t_{now} - o.t_{in} > o.TTL$  then
5:     Usuń  $o$  z arkusza (anulowanie)
6:   end if
7: end for
8: Krok 2: Procesowanie kolejki opóźnień
9: for każde zlecenie  $o_{new} \in latencyQueue$  do
10:  if  $t_{now} \geq o_{new}.t_{exec}$  then
11:    Przenieś  $o_{new}$  do silnika dopasowującego:
12:    if  $o_{new}$  jest typu MARKET then
13:      Dopasuj  $o_{new}.v$  do ofert przeciwnej strony, zaktualizuj wolumeny
14:    else if  $o_{new}$  jest typu LIMIT then
15:      if  $o_{new}.p$  krzyżuje się z ceną przeciwną then
16:        Wykonaj transakcję
17:      else
18:        Dodaj  $o_{new}$  do odpowiedniego zbioru  $A$  lub  $B$ 
19:      end if
20:    end if
21:    Usuń  $o_{new}$  z latencyQueue
22:  end if
23: end for

```

4.1.3 Mechanizm wymuszonego krachu (Flash Crash)

W celu zbadania odporności rynku na gwałtowne szoki, zaimplementowano funkcję `triggerCrash`. Reprezentuje ona szok egzogeniczny (zewnętrzny), który nie wynika bezpośrednio z logiki agentów, lecz z nagłego zdarzenia systemowego. Logika ta opiera się na dwóch filarach:

1. **Drenaż płynności:** Z obu stron arkusza (A i B) usuwane jest losowo $X\%$ zleceń oczekujących. Symuluje to masowe wycofywanie się animatorów rynku (*market makers*) w obliczu paniki.
2. **Korekta ceny fundamentalnej:** Cena bazowa instrumentu zostaje skokowo przesunięta w dół o zadaną wartość ΔP . Wymusza to na agentach typu *Momentum* kaskadową sprzedaż aktywów, co pozwala na obserwację powstawania spirali spadkowej.

Mechanizm ten pozwala na analizę czasu powrotu rynku do równowagi (tzw. *resilience*)

oraz badanie, czy obecność różnych typów agentów przyspiesza, czy opóźnia proces odbicia cenowego.

5. Realizacja praktyczna

W niniejszym rozdziale opisano szczegóły techniczne implementacji systemu symulacyjnego, wykorzystane narzędzia oraz architekturę rozwiązania łączącą analizę danych w języku Python z wydajnym silnikiem symulacyjnym w C++. Szczególną uwagę poświęcono optymalizacji wydajnościowej oraz metodom prezentacji wyników.

5.1 Założenia projektowe

Głównym założeniem projektu było stworzenie środowiska zdolnego do symulowania tysięcy transakcji w czasie zbliżonym do rzeczywistego. Do kluczowych wymagań i ograniczeń zaliczono:

- **Spójność arkusza zleceń:** Silnik musi bezwzględnie przestrzegać priorytetu ceny i czasu (FIFO) przy dopasowywaniu zleceń.
- **Efektywność obliczeniowa:** Ze względu na dużą liczbę agentów i operacji na arkuszu, rdzeń symulacji musi być zaimplementowany w języku niskopoziomym.
- **Równoległe przetwarzanie eksperymentów:** System powinien umożliwiać jednoczesne uruchamianie wielu instancji symulacji dla różnych zestawów parametrów, aby skrócić całkowity czas badań.
- **Parametryzacja z danych rzeczywistych:** Model wykorzystuje dynamiczne pobieranie danych rynkowych (Yahoo Finance), co wymaga stabilnej warstwy integracyjnej w Pythonie.

5.2 Komponenty sprzętowe

Do przeprowadzenia symulacji wykorzystano stacje robocze o architekturze wielordzeniowej. Dzięki zastosowaniu technik równoległych w warstwie sterującej, symulator w

pełni utylizuje dostępną moc obliczeniową:

- **Jednostka obliczeniowa:** Procesory o wysokiej liczbie wątków (np. AMD Ryzen lub Intel i7), co pozwala na jednoczesne przetwarzanie niezależnych scenariuszy eksperymentalnych.
- **Pamięć operacyjna:** Minimum 8 GB RAM dla zapewnienia płynnej wymiany danych między procesami symulatora a modułami analizy statystycznej.

5.3 Oprogramowanie i High Performance Computing

System został zbudowany z wykorzystaniem nowoczesnych standardów programistycznych, kładąc nacisk na wydajność typu HPC (*High Performance Computing*):

- **C++ (Standard 17/20):** Rdzeń *Matching Engine*. Zastosowano optymalne struktury danych (`std::map`, `std::list`), co gwarantuje złożoność czasową operacji na arkuszu na poziomie logarytmicznym lub stałym.
- **Python 3.x (Warstwa Orkiestracji):** Skrypt sterujący `run_experiments.py` wykorzystuje mechanizm wielowątkowości (`ThreadPoolExecutor`). Pozwala to na równoległe uruchamianie wielu instancji skompilowanego symulatora C++ na wszystkich dostępnych rdzeniach procesora, co drastycznie skraca czas generowania zbiorów danych dla 5 głównych scenariuszy badawczych.
- **Biblioteki analityczne:** `Pandas`, `NumPy` oraz `yfinance`.

5.4 Szczegóły implementacji i wizualizacja

Implementacja modelu została podzielona na moduły zapewniające czystość architektury i wysoką czytelność wyników.

5.4.1 Orkiestracja eksperymentów

Za zarządzanie procesem symulacji odpowiada moduł w Pythonie. Jego zadaniem jest:

1. Wygenerowanie plików parametrów (`.txt/.json`) dla C++.
2. Równoległe uruchomienie procesów binarnych.
3. Agregacja wyników w formatach CSV do dalszej obróbki.

5.4.2 Zaawansowana wizualizacja i redukcja szumu

Wyniki surowe z giełdy charakteryzują się bardzo wysokim poziomem szumu informacyjnego (pojedyncze, odbiegające transakcje). Aby umożliwić rzetelną interpretację wyników, w module wizualizacji zaimplementowano:

- **Wykładnicza średnia krocząca (EMA):** Zastosowanie filtrów EMA pozwala na wygładzenie krzywych cenowych i spreadu, uwypuklając rzeczywiste trendy rynkowe kosztem chwilowych fluktuacji.
- **Inteligentne skalowanie (Smart Zoom):** Algorytm automatycznie wykrywa i eliminuje wartości odstające (*outliers*), które mogłyby zaburzyć skalę wykresu, skupiając uwagę na obszarach o największej istotności statystycznej.

5.4.3 Repozytorium i uruchomienie

Kod źródłowy projektu dostępny jest w systemie kontroli wersji Git:

- **Link do repozytorium:**
<https://github.com/danielsterzel/Stock-market-simulation>
- **Instrukcja:** Po przygotowaniu środowiska (CMake, Python venv), główny proces badawczy uruchamia się komendą `python run_experiments.py`, która automatycznie zarządza cyklem życia symulacji i generuje raporty graficzne.

6. Rezultaty symulacji i analiza eksperymentalna


W niniejszym rozdziale przedstawiono wyniki pięciu kluczowych eksperymentów badawczych. Każdy z nich został zaprojektowany w celu odpowiedzi na konkretne pytanie badawcze dotyczące mikrostruktury rynku, stabilności systemowej oraz wpływu psychologii inwestorów na procesy cenowe.

6.1 Eksperyment 1: Wpływ struktury rynku na płynność (HFT vs Market Makers)

Cel i metodyka: Zbadano, jak proporcja między dostawcami płynności (*Market Makers*) a jej konsumentami (*HFT/Aggressive Agents*) wpływa na jakość rynku. Jako dane wejściowe wykorzystano notowania spółki o niskiej zmienności (tzw. „Blue Chip”).

Scenariusze:

- **1A (Dominacja Konserwatywna):** 90% Makers / 5% Aggressive.



Rysunek 6.1: Charakterystyka: Rynek "leniwy"

Błękitna linia ceny porusza się gładko, czasem z lekkim opóźnieniem względem danych wejściowych. Zjawisko "Szpilek" (Spikes): Na wykresie spreadu (średkowy) widać rzadkie, ale wysokie wysoki (do 5-8 jednostek). Wyjaśnienie: Ponieważ na rynku jest bardzo mało agresywnych graczy, transakcje zdarzają się rzadko. Gdy jednak nastąpi duże zlecenie Market, "wyjada" ono płynność z najlepszych poziomów. Ponieważ Market Makerzy w naszej symulacji mają opóźnienie (latency), mija chwila, zanim "dziura" w arkuszu zostanie załatana. Wniosek: Rynek jest bardzo bezpieczny, ale podatny na chwilowe braki płynności przy większych zleceniach.


- **1B (Rynek Agresywny):** Wysoki udział agentów HFT konsumujących arkusz.



Rysunek 6.2: Turbulencja

W okolicy kroku 300 i 600 widzimy ogromne skoki spreadu (do 20!) i ceny. Przyczyna: Jest to efekt "Tarcia Płynności" (Liquidity Friction). Mamy dużą siłę popytu (Agresywni) zderzającą się z dużą siłą podaży (Makerzy). Kiedy agresywni traderzy nagle przeważą, następuje gwałtowne przełamanie poziomów cenowych (breakout), co wywołuje lokalną panikę i eksplozję spreadu. Wniosek: Równowaga sił nie zawsze oznacza spokój. Intensywna walka o cenę generuje najwyższą zmienność (Volatility: 4.81).

- **Scenariusz 1C: Dominacja Agresywna** (10% Makers / 80% Agg)



Rysunek 6.3: Paradoks HFT

Spójrzmy na wykres spreadu (środkowy). Jest on najbardziej płaski i stabilny (utrzymuje się blisko 1.0-2.0), bez gigantycznych wyskoków jak w 1B. Wyjaśnienie: Przy 80% agresywnych spekulantów rynek jest niezwykle "szybki". Każda luka w cenie jest natychmiast wykorzystywana przez kolejnego spekulanta. Wysoki obrót (turnover) sprawia, że spread jest ciągle domykany. Koszt: Cena (wykres górny) jest "poszarpana" (jittery noise) – ciągle oscyluje góra-dół. Slippage (dolny wykres) ma wysoką podstawę, co oznacza, że handel jest drogi, ale przewidywalny.

Analiza i wnioski: Scenariusz 1A wykazał charakterystykę rynku „leniwego” – cena porusza się gładko, z minimalnym szumem. Dominacja zleceń typu *Limit* tworzy gęsty arkusz, który skutecznie tłumi nagłe skoki cenowe, jednak kosztem lekko opóźnionej

reakcji na gwałtowne zmiany trendu fundamentalnego.

6.2 Eksperyment 2: Test odporności rynku na szok podaży (Flash Crash)

Cel i metodyka: Weryfikacja stabilności rynku w warunkach ekstremalnego stresu. Wykorzystano dane indeksu S&P 500 (SPY) z kryzysu 2008 r. W 500. kroku symulacji wywołano sztuczny krach (*Crash Severity: 0.4*), usuwając znaczną część płynności.

Analiza i wnioski: Eksperyment wykazał, że rynek zdominowany przez *Market Makers* (Scenariusz 2A - 70% Konserwatywnych) pełni rolę bufora bezpieczeństwa. Mimo gwałtownego spadku ceny w momencie szoku, obecność gęstego arkusza zleceń oczekujących pozwoliła na relatywnie szybką renegocjację ceny i powrót do stabilnego handlu. W scenariuszach z mniejszą liczbą animatorów, *Flash Crash* prowadził do całkowitego "zamrożenia" rynku na wiele kroków symulacji.

6.3 Eksperyment 3: Mechanizm bańki i psychologia tłumu (Momentum)

Cel i metodyka: Badanie wpływu agentów śledzących trend (*Momentum Agents*) na stabilność wyceny na przykładzie spółki GameStop (GME).

Analiza wyników:

- **Scenariusz 3A (No Momentum):** Rynek efektywny, cena wiernie śledzi fundamenty. Spread stabilny (1.18).
- **Scenariusz 3C (High Momentum - 70%):** Obserwujemy drastyczne załamanie efektywności. W kroku $t = 180$ wystąpiło zjawisko **Overshootingu** – cena rynkowa zanurkowała znacznie głębiej niż fundamentalna.

Wnioski: Agenci Momentum generują dodatnie sprzężenie zwrotne. Mały spadek ceny inicjuje lawinę zleceń sprzedaży (*Panic Selling*), co prowadzi do eksplozji spreadu (wzrost do poziomu 8.0). Zmienność wzrosła z 0.76 (rynek racjonalny) do 1.71 (rynek emocjonalny).

6.4 Eksperyment 4: Granica płynności (Liquidity Cliff) na walorach Nvidia

Cel i metodyka: Identyfikacja punktu załamania systemu (*Breakdown Point*) przy drastycznym ograniczeniu liczby animatorów rynku na danych spółki Nvidia (NVDA).

Analiza wyników:

- **Scenariusz 4A (10% Makers):** Rynek „szpilkowy”. Spread regularnie skacze do poziomu 5-8 jednostek, gdy agresywne zlecenia czyszcą arkusz, ale system wciąż wykazuje zdolność do regeneracji.
- **Scenariusz 4B (2% Makers):** Strukturalne załamanie. Spread tworzy szerokie, prostokątne bloki (*Plateau Spread*) i nie wraca do normy.

Wnioski: Eksperyment potwierdził istnienie zjawiska **Liquidity Cliff**. Poniżej progu ok. 5% animatorów, rynek traci zdolność do samoregulacji. Koszty poślizgu cenowego (*Slippage*) w scenariuszu 4B osiągały drastyczne wartości 50-100 jednostek, co w praktyce uniemożliwia efektywny handel.

6.5 Eksperyment 5: Walidacja techniczna modelu (Tracking Error)

Cel i metodyka: Techniczna walidacja silnika dopasowującego na danych syntetycznych (sinusoida z szumem Gaussa). Porównano rynek zrównoważony (5A) z rynkiem zdominowanym przez *Makerów* (5B - 80%).

Analiza wyników:

- **Jakość śledzenia:** W obu przypadkach cena symulowana wiernie podąża za sinusoidą, co potwierdza brak błędów kumulacyjnych w silniku C++.
- **Szum endogeniczny:** Nawet przy idealnych danych wejściowych, mikrostruktura generuje szum. W scenariuszu 5B zaobserwowano piki zmienności (*Volatility*: 3.62) w punktach zwrotnych sinusoidy.

Wnioski: Przy zbyt dużym udziale *Market Makerów* (80%), rynek staje się „ciężki” – konieczność masowego anulowania i wystawiania zleceń przy zmianie trendu powoduje chwilowe rozjechanie się spreadu i skoki zmienności.

6.6 Podsumowanie wyników eksperymentalnych

Przeprowadzone badania dowodzą, że płynność giełdowa nie jest wartością stałą, lecz dynamicznym wynikiem interakcji między różnymi typami agentów. Kluczowym wnioskiem jest potwierdzenie, że zarówno niedobór animatorów (Eksperyment 4), jak i nadmiar agentów śledzących trend (Eksperyment 3) prowadzą do destabilizacji systemu, mimo różnych mechanizmów przyczynowych.

7. Dyskusja wyników

W niniejszym rozdziale dokonano syntezy wyników uzyskanych w toku pięciu eksperymentów symulacyjnych. Przeprowadzona analiza pozwoliła na sformułowanie kluczowych wniosków dotyczących wpływu mikrostruktury rynku na kształtowanie się cen, płynności oraz ryzyka transakcyjnego.

7.1 Trade-off płynności: stabilność vs koszt

Jednym z najważniejszych odkryć badania (na podstawie Eksperymentów 1 i 2) jest zidentyfikowanie fundamentalnego kompromisu (*trade-off*) pomiędzy stabilnością ceny a kosztem transakcyjnym.

- **Rola Market Makerów:** Symulacje wykazały, że wysoki udział agentów konserwatywnych działa jak systemowy „amortyzator”. W warunkach szoku (*Flash Crash*, Exp 2A), cena rynkowa reagowała z opóźnieniem względem gwałtownego spadku fundamentu, co w teorii daje inwestorom czas na reakcję. Odbywa się to jednak kosztem drastycznego wzrostu spreadu. Bezpieczeństwo rynku jest więc „kupowane” za cenę wyższych kosztów transakcyjnych w okresach stresu.
- **Kruczość rynku spekulacyjnego:** Rynki zdominowane przez spekulantów charakteryzują się bardzo niskim spreadem w czasie spokoju, ale są strukturalnie kruche. Brak zleceń *Limit* po stronie popytowej w momencie krachu powoduje, że cena „przepada” w dół niemal natychmiastowo, a głębokość rynku zanika, generując ekstremalny poślizg cenowy (*Slippage*).

7.2 Zjawisko „Urwiska Płynności” (Liquidity Cliff)

Eksperyment 4 przeprowadzony na danych spółki Nvidia dostarczył dowodów na nieliniową naturę płynności rynkowej. Wykazano istnienie tzw. masy krytycznej animatorów rynku.

Symulacja sugeruje, że spadek udziału *Market Makerów* poniżej progu ok. 5–8% populacji prowadzi do systemowego załamania się mechanizmu cenotwórczego. Poniżej tego progu spread nie rośnie liniowo, lecz skokowo, tworząc trwałe blokady w handlu. Jest to wniosek istotny z punktu widzenia regulatorów giełdowych – sugeruje on, że całkowita automatyzacja rynku przez strategie agresywne (bez odpowiednich zachęt dla dostawców płynności) może prowadzić do powstawania rynków dysfunkcyjnych.

7.3 Psychologia tłumu i zjawisko „Overshootingu”

Analiza bańki spekulacyjnej (Eksperyment 3 na danych GME) potwierdziła skuteczność zaimplementowania agentów typu *Momentum* w modelowaniu irracjonalnych zachowań rynku.

Wykazano, że już 30-procentowy udział agentów śledzących trend wystarczy, aby wywołać zjawisko „przestrzelenia” ceny (*Overshooting*). Cena rynkowa odrywa się od fundamentów w wyniku dodatniego sprzężenia zwrotnego: wzrost ceny inicjuje zakupy agentów momentum, co generuje dalszy wzrost. Mechanizm ten działa symetrycznie podczas spadków – agenci potęgują panikę (*Panic Selling*), co w symulacji było widoczne jako gwałtowne, pionowe „szpilki” spadkowe, znacznie przekraczające realną utratę wartości aktywa.

7.4 Weryfikacja techniczna i wpływ opóźnień (Latency)

Eksperyment walidacyjny z wykorzystaniem sinusoidy potwierdził wpływ opóźnień (*latency*) na mikrostrukturę arkusza. Regularne skoki spreadu widoczne na wykresach są bezpośrednim skutkiem modelowanego czasu reakcji agentów.

Gdy agresywne zlecenie konsumuje dostępną płynność, w arkuszu powstaje luka, która „żyje” przez czas odpowiadający opóźnieniu agentów konserwatywnych. Jest to zjawisko całkowicie zgodne z obserwacjami na rzeczywistych rynkach wysokiej częstotliwości (HFT), gdzie walka o mikrosekundy decyduje o możliwości wypełnienia takiej luki i stabilizacji ceny.

7.5 Ograniczenia modelu

Mimo uzyskania spójnych wyników, model posiada ograniczenia wynikające z przyjętych uproszczeń:

- **Brak czynników makroekonomicznych:** Agenci reagują wyłącznie na cenę i fundament, ignorując czynniki zewnętrzne, takie jak stopy procentowe czy wiadomości ze świata.
- **Uproszczona topologia opóźnień:** W rzeczywistości opóźnienia są stochastyczne; w modelu przyjęto stałe klasy opóźnień dla poszczególnych typów agentów.
- **Brak kosztów transakcyjnych:** Model nie uwzględnia prowizji giełdowych i podatków, które w realnym świecie hamują strategie o bardzo wysokiej częstotliwości (tzw. *Noise Trading*).

8. Podsumowanie

Niniejszy projekt stanowił kompleksową próbę odtworzenia i analizy dynamiki współczesnego rynku kapitałowego przy wykorzystaniu zaawansowanych technik modelowania agentowego (ABM). W toku realizacji prac udało się stworzyć wydajny i stabilny numerycznie silnik symulacyjny w języku C++, który w połączeniu z warstwą analityczną w języku Python, pozwolił na wieloaspektowe zbadanie mikrostruktury giełdy.

8.1 Realizacja celów projektu

Główne cele postawione przed zespołem zostały w pełni zrealizowane. Udało się nie tylko zaimplementować teoretyczny model Mike-Farmer, ale również wzbogacić go o autorskie komponenty, takie jak mechanizm kolejki opóźnień (*latency queue*), logikę agentów momentum oraz systemy generowania szoków rynkowych. Synergiczne połączenie wysokowydajnego kodu niskopoziomowego z dynamicznym pobieraniem danych z API Yahoo Finance umożliwiło przeprowadzenie symulacji w oparciu o realne scenariusze rynkowe, co znacząco podniosło wartość merytoryczną projektu.

8.2 Wnioski merytoryczne

Przeprowadzona seria eksperymentów dostarczyła istotnych wniosków dotyczących natury procesów giełdowych:

- **Interdyscyplinarność modelu:** Wykazano, że połączenie psychologii inwestorów (agenci momentum) z technicznymi parametrami sieciowymi (opóźnienia) pozwala na generowanie zjawisk takich jak bańki spekulacyjne czy nagłe załamania płynności, które są niemożliwe do opisania prostymi modelami regresyjnymi.
- **Kruchość nowoczesnej płynności:** Analiza „urwiska płynności” (Eksperyment 4) pokazała, jak niebezpieczne dla stabilności systemu może być zdominowanie handlu przez algorytmy agresywne przy jednoczesnym braku animatorów rynku.

- **Walidacja technologiczna:** Sukces eksperymentu z sinusoidą potwierdził, że zaimplementowany algorytm dopasowujący (*Matching Engine*) jest wolny od błędów logicznych i może służyć jako stabilne narzędzie do dalszych badań nad mikrostrukturą rynku.

8.3 Perspektywy rozwoju

Mimo wysokiej kompletności raportu, projekt otwiera liczne ścieżki dalszej rozbudowy. Potencjalne kierunki rozwoju obejmują:

1. **Integracja uczenia maszynowego:** Zastąpienie prostych reguł agentów sieciami neuronowymi (np. *Reinforcement Learning*), co pozwoliłoby na badanie ewolucji strategii handlowych.
2. **Modelowanie wieloaktywowe:** Rozszerzenie symulacji o wiele skorelowanych instrumentów w celu badania zjawiska zarażania kryzysem (*financial contagion*).
3. **Dalsza optymalizacja HPC:** Wykorzystanie technik programowania równoległego na GPU (CUDA) w celu zwiększenia skali populacji agentów do milionów jednostek.

8.4 Podsumowanie końcowe

Podsumowując, projekt pozwolił na głębokie zrozumienie procesów kształtujących współczesne rynki finansowe. Stworzone narzędzie udowodniło, że symulacje komputerowe są nieodzownym elementem nowoczesnej inżynierii finansowej, pozwalającym na bezpieczne testowanie hipotez ekonomicznych w kontrolowanym środowisku laboratoryjnym. Zdobyte doświadczenie w zakresie łączenia wydajnego kodu C++ z analitycznymi bibliotekami Pythona stanowi solidny fundament dla przyszłych zadań z obszaru modelowania systemów złożonych i analizy danych wysokiej częstotliwości.

Bibliografia

- [1] S. Mike and J. D. Farmer, “An empirical behavioral model of liquidity and volatility,” *Journal of Economic Dynamics and Control*, vol. 32, no. 1, pp. 200–234, 2008.
- [2] D. K. Gode and S. Sunder, “Allocative efficiency of markets with zero-intelligence agents: Market-level outcomes with an individual thrift constraint,” *Journal of Political Economy*, vol. 101, no. 1, pp. 119–137, 1993.
- [3] A. Ntakaris, M. Magris, J. Kannianen, M. Gabbouj, and A. Iosifidis, “Benchmark dataset for mid-price forecasting of limit order books with machine learning,” *Journal of Forecasting*, vol. 37, no. 8, pp. 852–866, 2018.
- [4] M. D. Gould, M. A. Porter, S. Williams, M. McDonald, D. J. Fenn, and S. D. Howison, “Limit order books,” *Quantitative Finance*, vol. 13, no. 11, pp. 1709–1742, 2013.
- [5] W. McKinney *et al.*, “Data structures for statistical computing in python,” in *Proceedings of the 9th Python in Science Conference*, vol. 445, 2010, pp. 51–56.
- [6] B. Marjanovic, “Huge stock market dataset,” <https://www.kaggle.com/borismarjanovic/price-volume-data-for-all-us-stocks-etfs>, 2017, dostęp: 2024-05-20.
- [7] J. D. Farmer and D. Foley, “The economy needs agent-based modelling,” *Nature*, vol. 460, no. 7256, pp. 685–686, 2009.